BikeShare Analytics

자전거 대여 수요 예측
데이터 분석 보고서

2011–2012 데이터 기반 EDA · 모델링 · 운영 전략 최적화

작성일자
2026-03-04

최종 성과 (RMSLE)
0.33980

작성자
전미정

목차

01 분석 배경 및 목표

02 데이터 개요 & 변수 설명

03 가설 설정 및 검증

04 EDA: 시간대·요일 패턴

EDA: 날씨·온도·조합

EDA 시각화 ① 시간대 패턴

EDA 시각화 ② 날씨·온도·조합

05 데이터 전처리 요약

06 1차·2차 모델링(Linear)

3차·최종 모델링(XGB vs Dual)

07 모델 성능 비교

08 오차 분석 결과

09 핵심 인사이트

10 운영 전략 제안

11 결론 및 향후 방향

부록: 기후·지역 추정

분석 배경 및 목표

페르소나

자전거 대여 시스템 운영 담당자로서 효율적인 자전거 배치 및 운영 최적화를 수행

최종 목표

날씨·시간·계절 변수를 활용해 **시간대별 대여 수요 (count)를 정확히 예측**하는 모델 개발

평가 지표

RMSLE

Root Mean Squared Logarithmic Error

mean_squared_log_error 기반

- 예측값과 실제값의 **로그 차이**를 평가
- 저수요·고수요 구간의 오차를 **균형 있게 반영**
- 과소/과대 준비 리스크 완화에 적합한 운영 지표

데이터 개요 & 변수 설명

데이터 규모

Train Set
10,886 rows
12 columns

Test Set
6,493 rows
9 columns

데이터 품질

0 Missing Values

모든 컬럼 결측치 없음 (Clean)

타깃 (count) 분포

Mean	191.6
Median	145.0
Max	977.0

우편향 (Right Skewed) 분포

주요 변수 처리 전략

Feature Engineering Plan

변수명	설명 및 특징	처리 전략
datetime	날짜 및 시간 데이터 (2011-2012)	Feature Gen
season	계절 (1:봄, 2:여름, 3:가을, 4:겨울)	One-Hot
weather	날씨 상태 (1:맑음 ~ 4:폭우/폭설)	One-Hot
temp	기온 (°C)	Use
atemp	체감온도 (temp와 상관계수 0.985)	Drop
humidity	상대 습도 (%)	Use
windspeed	풍속	Use
casual	비회원 대여수 (Train Only)	Dual Target
registered	회원 대여수 (Train Only)	Dual Target
count	**총 대여수 (Target Variable)**	Log Trans

가설 설정 및 검증

H1 **평일/주말 시간대 패턴이 구조적으로 다름** ✓ 확인

평일: 출퇴근 **이중 피크** (08, 17-18시) vs 주말: 낮 시간 **단일 피크** (12-16시)

`Vis: pointplot`

H2 **날씨 상태(Weather 1~4)에 따라 수요 차이가 존재** ✓ 확인

Weather(1) > Weather(2) > Weather(3) > Weather(4) 순으로 수요 급감 확인

`Data: weather_profile`

H3 **출퇴근 여부 × 날씨 조합(Interaction)이 수요에 영향** ✓ 확인

rush_weather 조합 분석 결과, '출퇴근시간+맑음'에서 압도적 수요 확인

`Vis: boxplot`

H4 **기상 변수(온도/습도/풍속) 구간별 수요 차이 존재** ✓ 확인

temp_band(20~30°C 최대), humidity_band(저습 유리) 등 구간별 차이 뚜렷

`Vis: barplot`

H5 **사용자 그룹(Casual/Registered) 분리 예측이 성능 개선에 기여** ✓ 확인

Dual XGBoost 도입 시 **RMSLE 0.33980** 달성 (Baseline 대비 67% 개선)

`Model: Dual XGB`

EDA: 시간대·요일 패턴

> Hour(시간대)가 수요 변동을 **가장 크게 설명**하는 핵심 변수

평일 (Working Day)

- 출퇴근 시간대에 명확한 **이중 피크(Bimodal)** 패턴 발생
- 오전 **08시** / 오후 **17~18시**에 수요 집중
- 주 이용 목적: **통근·통학** (Commuting)

Vis Reference: pointplot (workingday=1)

주말 (Weekend)

- 낮 시간대에 완만한 **단일 피크(Unimodal)** 패턴 발생
- 오전 **10시 ~ 오후 16시** 사이에 넓게 분포
- 주 이용 목적: **여가·레저** (Leisure)

Vis Reference: pointplot (workingday=0)

EDA: 날씨 · 온도 · 조합

> 날씨 상태에 따른 **기상 변수의 뚜렷한 차이**와 구간화된 조합 변수의 유의미한 패턴을 확인

기상 변수 프로파일링

- **Weather 1 (맑음)**: 평균 기온 20.6°C, 습도 56.7%로 가장 쾌적하며 대여량이 가장 높음
- **Weather 4 (폭우)**: 평균 기온 8.2°C, 습도 86%로 악천후 특성을 보이며 수요 급감
- 날씨 코드가 증가할수록(악천후) 기온은 낮아지고 습도는 높아지는 경향 뚜렷

Avg Temp	Avg Humidity	Avg Wind
20.2°C	61.9%	12.8

조합 변수 & 구간화 분석

- **Rush_Weather**: '출퇴근×맑은날(1_W1)' 조합에서 압도적인 대여량 확인 (운영 최우선 순위)
- **Temp Band**: Warm(20~30°C) 구간에서 최대 수요, Extreme Hot(35°C↑) 구간에서 소폭 감소
- **Humidity Band**: 습도가 높아질수록(Humid) 대여량이 선형적으로 감소하는 음의 상관관계
- **Windspeed Band**: 적당한 풍속(Medium)에서 수요가 가장 높으며, 강풍 시 안전 문제로 감소

EDA 시각화 ① — 시간대 패턴

시간대별 평균 대여량

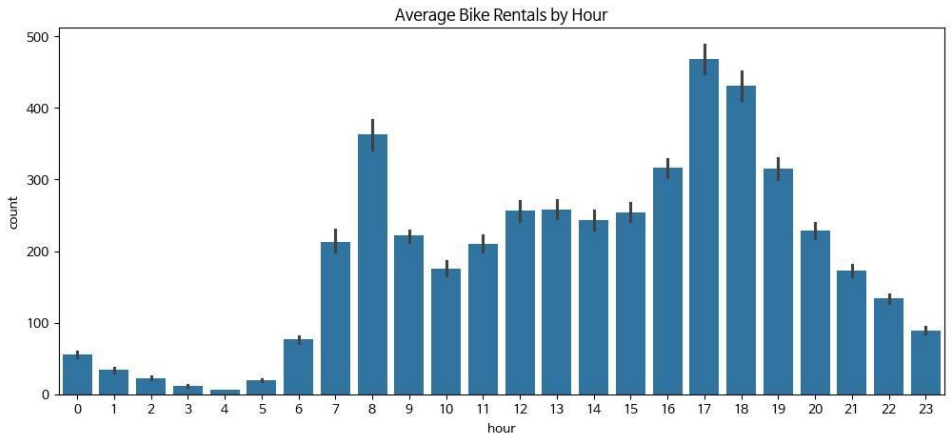

오전 8시(364대), 오후 17~18시(466대)에 수요가 집중되는 **출퇴근 이중 피크** 패턴을 보입니다.

평일 vs 주말 시간대 패턴

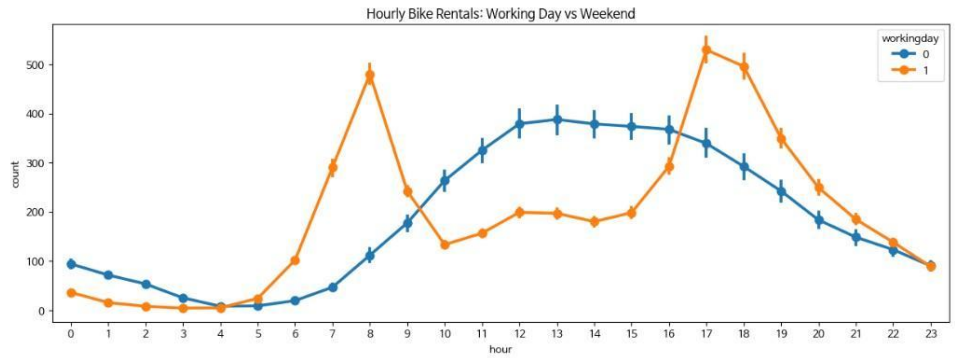

평일(주황)은 출퇴근 시간에 집중되지만, 주말(파랑)은 **낮 시간(10-16시)**에 완만하게 분포하는 단일 피크를 형성합니다.

EDA 시각화 ② — 날씨·온도·조합변수 분석

계절별 온도 vs 대여량

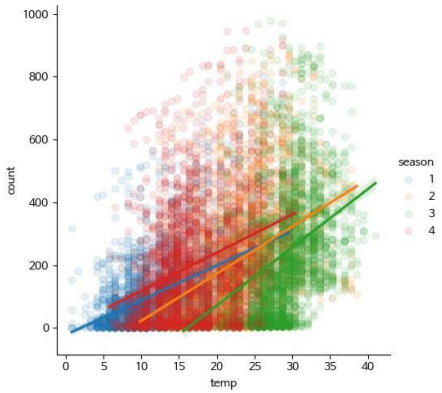

온도&계절 조합별 평균 대여량

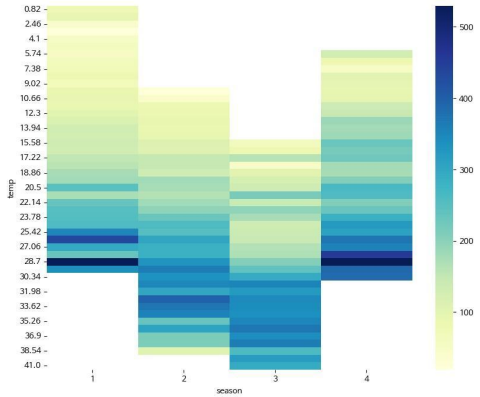

Rush Hour × Weather

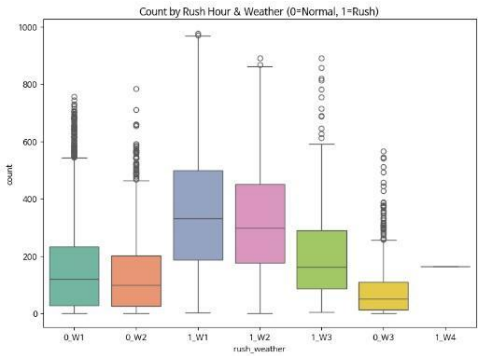

출퇴근+맑음(1_W1) 압도적

온도 구간별 (Temp)

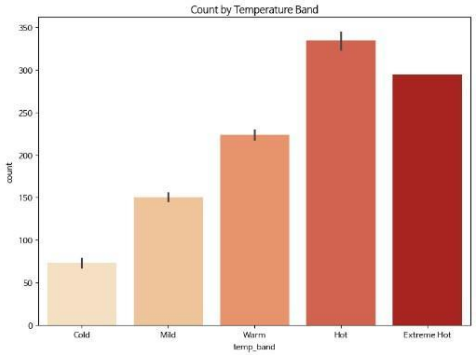

Warm(20~30°C) 최대 수요

습도 구간별 (Humidity)

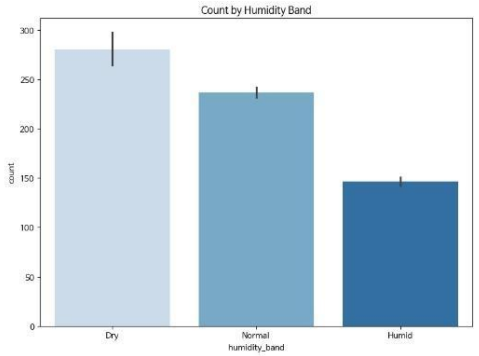

습도 상승 시 선형 감소

풍속 구간별 (Windspeed)

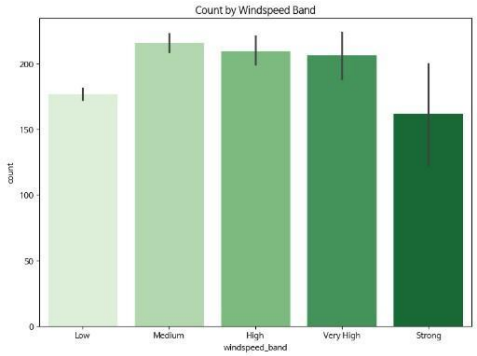

적정 풍속(Medium) 선호

데이터 전처리 요약

1

Datetime 분해

시계열 데이터를 5개 파생 변수로 분해하여 패턴 학습 지원

year, month, day, **hour**, dayofweek

2

변수 제거

다중공선성 및 불필요 변수 제거

atemp drop (temp와 corr 0.985)

casual, registered 제외 (예측 대상)

3

타깃 로그 변환

우편향된 타깃 변수를 정규분포에 근사시킴

np.log1p(count)

* Dual 모델: casual/registered 개별 로그 변환

4

원-핫 인코딩 & Align

범주형 변수 변환 및 Train/Test 컬럼 동기화

season, weather, hour, month, year (drop_first=True)

```
align(..., fill_value=0)
```

5

데이터 분할

학습/검증 데이터셋 분리 (8:2)

Train: 8,708 (80%)

Val: 2,178 (20%)

v2 Shape: (N, 53)

1차·2차 모델링 비교

1차 모델링 (Baseline)

RMSLE Score

1.02508

* 원스케일 RMSLE: 1.30920

- **Algorithm:** Linear Regression
- **Features:** 17개 (기본 변수)
- **Target:**np.log1p(count) 적용
- 선형 모델의 한계로 비선형적 시간 패턴(출퇴근 등) 포착 미흡

2차 모델링 (Improved)

43.3% Improved

RMSLE Score

0.58097

Baseline 대비 대폭 개선

- **Algorithm:** Linear Regression + **OHE**
- **Features:** 17개 → **53개** (확장)
- **Key Action:** 범주형 변수(season, weather, hour 등) 원-핫 인코딩 적용
- 시간대별(Hour) 독립적 가중치 학습으로 비선형 패턴 포착

3차 · 최종 모델링 — XGB vs Dual

3차 모델링 (XGBoost)

RMSLE Score

0.34811

Algorithm: XGBoost Regressor

Hyperparams:
n_estimators=1000, depth=6, lr=0.05, early_stopping=50

Process:
`log1p(count)` → 예측 → `expm1` 복원
(음수 예측값 0 처리)

Interpretation:
feature_importances_ + SHAP 분석으로 주요 변수(hour, temp, year) 영향력 확인

최종 모델링 (Dual XGBoost)

Final RMSLE Score

0.33980

Δ -0.00831 (-2.38%)

Core Mechanism: Target Separation

Formula:
`pred = expm1(casual) + expm1(registered)`

Key Insight:
동일 입력(X_v2)에서 타깃을 분리하여 2개 모델 독립 학습 → 그룹별 상이한 패턴 포착

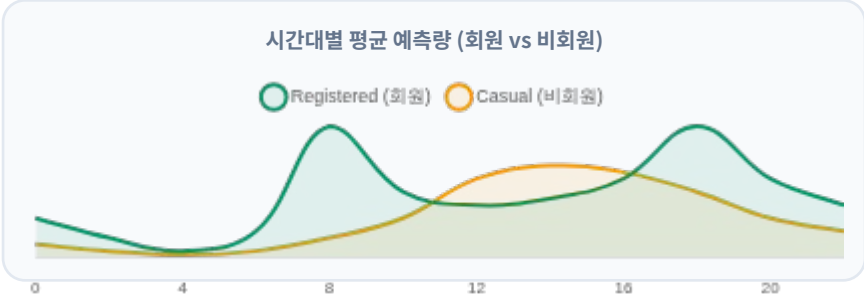

모델 성능 비교

RMSLE Score Evolution (Lower is Better)

1	2	3	✓
Baseline (Log)	Linear + OHE	XGBoost	Dual XGBoost
1.02508	0.58097	0.34811	0.33980
Start	-43.3%	-40.1%	Final

Total Improvement

Baseline 모델 대비 오차 감소율

66.9% ↓

(1.025 → 0.339)

Key Contributor

1. Feature Engineering:
Time features (Hour OHE)

2. Model Selection:
Tree-based Ensemble (XGB)

Winning Strategy

Target Separation (Dual)

회원(Registered)과 비회원(Casual)의 상이한 이용 패턴을 분리하여 개별 예측 후 합산

오차 분석 결과

잔차 분석 시각화 (Residual Analysis)

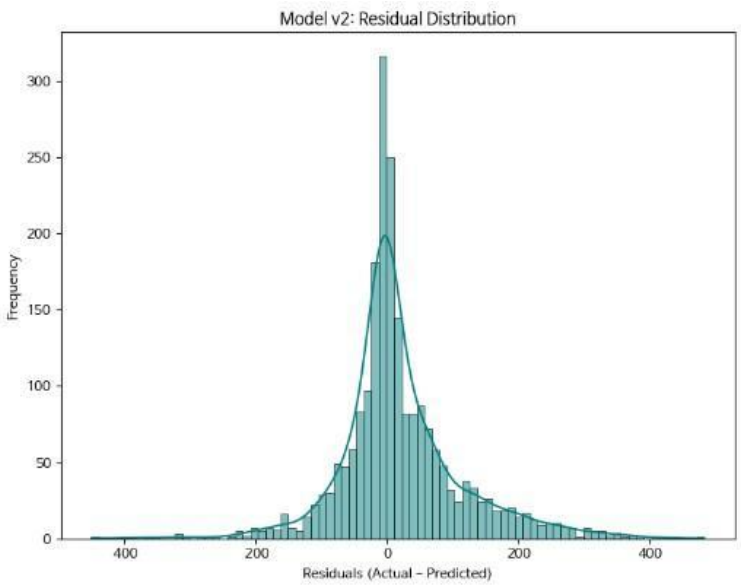

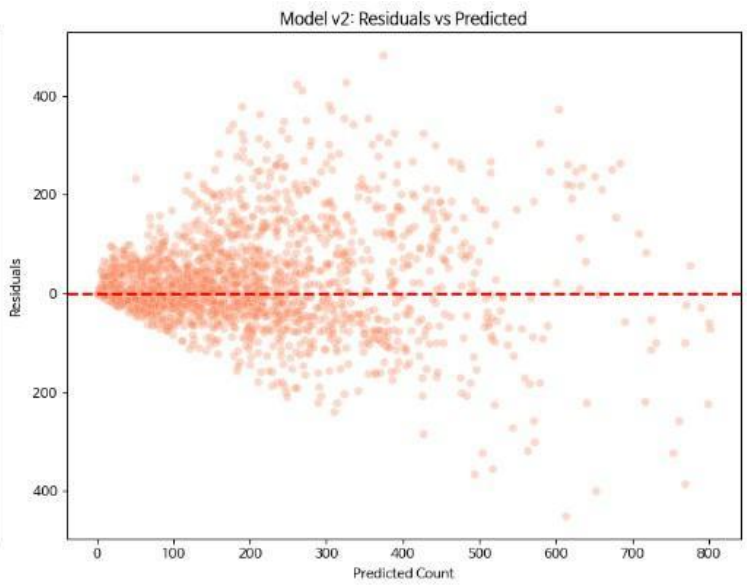

핵심 오차 패턴 (Error Pattern)

1. 이분산성(Heteroscedasticity) 확인:
예측값(Predicted Value)이 커질수록 잔차의 분산도 함께 증가하는 패턴이 관찰되며, 이는 선형 모델의 한계를 시사합니다.

2. 과소예측 경향:
잔차 분포가 0을 중심으로 하되, 양수 방향(Actual > Predicted)으로 긴 꼬리를 형성하여 피크 수요 시 과소예측 경향을 보입니다.

개선 전략 (Action Plan)

1. 비선형 모델 도입:
선형 회귀의 한계를 극복하기 위해 **Tree-based (XGBoost)** 모델 도입을 결정했습니다.

2. 타깃 분리 학습:
특정 시간/날씨 조합 구간의 큰 오차를 해결하기 위해 사용자 그룹별(Casual/Registered)로 분리하여 예측 모델을 구축합니다.

핵심 인사이트

시간대(Hour)가 강력한 지표

대여 수요 변동의 가장 큰 요인은 **시간대**임.
하루 중 수요 패턴(출퇴근 vs 낮 시간)이
명확하게 구분됨.

평일/주말 패턴의 구조적 차이

평일: 출퇴근 시간(8시, 17~18시) 이중 피크
주말: 낮 시간(12~16시) 단일 피크
→ 요일별 운영 전략 차별화 필수

날씨 그룹별 기상 지표 평균 차이

Weather 1(맑음)에서 수요가 가장 높으며, 악천후 (Weather 3, 4) 시 급감.
특히 습도와 풍속이 날씨 그룹별로
뚜렷한 차이를 보임.

출퇴근 × 날씨 조합별 수요 분포

rush_weather 조합 분석 결과,
'출퇴근 시간 + 맑은 날씨' 조합에서
압도적인 수요 집중 확인.

기상 변수 구간화 시 수요 차이

Temp: 20~30°C 구간 최대
Humidity: 낮을수록 증가
Windspeed: 적당한 바람에서 최대
→ 비선형적 관계 확인

Dual 분리로 성능·설명력 강화

회원(Registered)과 비회원(Casual)을
분리 예측함으로써 모델 성능(RMSLE)을
대폭 개선하고, 그룹별 행동 패턴 이해도 제고.

운영 전략 제안

시간대 차등 배치

평일/주말 패턴 반영:
평일은 **08시, 17~19시** 출퇴근 거점에 집중 배치하고, 주말은 **12~16시** 여가 지역 위주로 유동적 재배치 시행.

Day-Mode Switching

Workingday 기준 운영:
평일(Working Mode)과 주말/공휴일(Holiday Mode)의 운영 매뉴얼을 이원화하여 인력 및 자원 배분 최적화.

날씨 기반 탄력 운영

Weather Profile & Rush_Weather:
악천후 예보 시(Weather 3, 4) 가동률을 축소하여 유지보수 전환,
맑은 날 출퇴근 시간대 가용 자원 100% 투입.

기상 변수 구간별 대응

Band 기반 세밀화:
온도 20~30°C(최적 구간) 및 적정 풍속/습도 구간에서 수요 폭증 대비 예비 물량 확보.

사용자군 맞춤 운영

Dual Model Insight

회원(Registered):
출퇴근 정기권 혜택 강화 및 거점 스테이션 우선 배차

비회원(Casual): 주말 관광지/공원 인근 임시 거치대 운영 및 프로모션 진행

결론 및 향후 방향

Final Model (Dual XGBoost)

0.33980

Baseline(Log) **1.025** -> **0.339** (RMSLE)

핵심 결론 (Key Findings)

- **Log Transformation:** 타깃 변수의 우편향 분포 보정 (필수 전처리)
- **One-Hot Encoding:** 시간/계절 등 범주형 변수의 비선형 패턴 학습 유도
- **Target Separation (Dual):** 회원/비회원 그룹 분리 예측이 성능 향상의 핵심 요인

Future Roadmap (향후 개선 과제)

Lag/Rolling Feature

전일/전주 동시간대 대여량 등 시계열 연속성을 반영하는 파생 변수 도입 검토

Hyperparameter Tuning

Optuna 또는 Bayesian Optimization을 활용한 정밀 튜닝으로 모델 최적화

Ensemble/Stacking

추후 모델을 더 발전시키기 위한 다른 알고리즘의 적용 필요

External Data

강수량 상세 데이터, 지역 행사/이벤트 정보 등 외부 데이터 결합을 통한 설명력 보완

부록: 기후·지역 추정 분석

기온 패턴 (Temperature)

- **연평균 기온:** 약 20°C (데이터 정규화 기준)
- **계절적 특징:** 여름(6~8월) 평균 **30°C**, 겨울(12~2월) 평균 **5~7°C**
- **기후 유형:** 뚜렷한 사계절을 가진 **습윤 대륙성 기후** 패턴과 일치

습도 패턴 (Humidity)

- **연평균 습도:** 정규화 값 약 0.63 (63%)
- **계절적 특징:** 여름철 고습(**75~80%**), 겨울철 상대적 저습(**45~55%**)
- **지역적 특징:** 전형적인 **북미 동부 해안 도시**의 다습한 여름 특성 반영

강수 패턴 (Weather Condition)

- **날씨 비율:** 맑음 **66.4%** / 흐림 27.9% / 눈·비 5.0% / 폭우·안개 0.07%
- **강수 분포:** 특정 계절에 편중되지 않고 **연중 고르게 분포**하는 경향
- **운영 시사점:** 맑은 날 비율이 높아 자전거 이용에 유리한 환경

지역 특성 추정 근거

기후 유형별 해당 지역 추정

① 온대 해양성 기후 (Cfb)
서유럽·북서 미국·캐나다 해안·뉴질랜드·호주 남동부
→ 겨울 5~10°C / 여름 18~22°C, 연중 습하고 바람 많음

② 습윤 아열대 해안 (Cfa)
일본 태평양 연안·미국 동남부·동호주 해안
→ 여름 25~30°C 이상, 평균 20°C는 늦봄·초가을 구간 추정

주의: 위치 정보 없음 — 기후 패턴 기반 추정